

Guide d'installation : Agent Hermes & IA Locale (Ollama)

Documentation technique officielle pour un déploiement 100% privé et sécurisé.

Bienvenue dans cette documentation technique. Ce guide vous explique comment installer l'agent **Hermes**, le coupler avec **Ollama** pour faire tourner une Intelligence Artificielle en local (sans connexion internet requise), et choisir le modèle d'IA adapté à votre machine.

1. Présentation générale

L'agent **Hermes** est un assistant virtuel capable d'exécuter des scripts, d'automatiser des tâches et de répondre à vos requêtes. En le connectant à **Ollama**, vous bénéficiez d'une solution 100% privée : aucune donnée textuelle ne quitte votre ordinateur.

2. Prérequis Système

Avant de commencer, assurez-vous que votre configuration matérielle est suffisante :

- **Système d'exploitation** : Windows 10/11, macOS, ou Linux (Ubuntu/Debian conseillé).
- **Processeur (CPU)** : Récent (Intel i5/i7 ou AMD Ryzen 5/7 minimum).
- **Mémoire RAM** :
 - 8 Go : Strict minimum (modèles très légers).
 - 16 Go : Recommandé pour le confort.
 - 32 Go : Idéal pour les grands modèles.
- **Carte graphique (GPU)** : Fortement recommandée (NVIDIA avec support CUDA ou puces Apple Silicon M1/M2/M3) pour une vitesse d'exécution fluide.

3. Étape 1 : Installation de l'Agent Hermes

L'agent Hermes se récupère généralement via son dépôt de code. Ouvrez votre terminal (ou invite de commandes).

Sous Linux / macOS

```
# Cloner le projet depuis le dépôt
git clone https://github.com/hermes-agent/core.git hermes-agent

# Entrer dans le dossier
cd hermes-agent

# Installer les dépendances du projet
npm install
```

Sous Windows

Utilisez **PowerShell** ou votre terminal habituel :

```
git clone https://github.com/hermes-agent/core.git hermes-agent
cd hermes-agent
npm install
```

4. Étape 2 : Installation de Ollama

Ollama est le moteur qui permet de faire tourner les modèles d'IA localement.

- Téléchargez l'installateur correspondant à votre système sur le site officiel d'Ollama.
- Lancez le fichier téléchargé et suivez les instructions d'installation classiques.
- Une fois installé, vérifiez qu'Ollama est actif en ouvrant un terminal et en tapant :

```
ollama --version
```

5. Étape 3 : Liste et choix des modèles d'IA

Il existe une multitude de modèles (les "cerveaux" de l'IA). Vous devez en choisir un selon vos ressources et la langue souhaitée.

Nom du Modèle	Taille	RAM requise	Spécificités & Points forts
Mistral (7B)	~4.1 Go	8 Go	Recommandé pour le français. Conçu par une équipe française, il est très percutant et rapide.
Llama 3 (8B)	~4.7 Go	8 Go - 16 Go	Développé par Meta. Excellent pour le raisonnement général et le code (très performant en anglais).
Phi-3 (Mini)	~2.2 Go	4 Go	Développé par Microsoft. Ultra-léger, idéal si vous n'avez pas de carte graphique ou un vieux PC.
Gemma (7B)	~4.8 Go	16 Go	Développé par Google. Très efficace pour la création de contenu et l'analyse de texte.
CodeGemma	~4.8 Go	16 Go	Version optimisée pour l'assistance au développement informatique (Python, JS, C++, etc.).

Téléchargement du modèle

Pour installer le modèle de votre choix (par exemple **Mistral**), exécutez simplement la commande suivante dans votre terminal :

```
ollama run mistral
```

Note : Le premier téléchargement peut prendre plusieurs minutes selon votre vitesse de connexion.

6. Étape 4 : Connexion entre Hermes et Ollama

Il faut maintenant indiquer à l'agent Hermes qu'il doit interagir avec l'IA que vous venez d'installer.

- Dans le dossier de votre agent Hermes, localisez le fichier de configuration (souvent nommé `.env` ou `config.json`).
- Ouvrez-le avec un éditeur de texte (Notepad++, VS Code, etc.).
- Adaptez les variables de configuration comme suit :

```
CORE_LLM_PROVIDER="ollama"
CORE_LLM_URL="http://localhost:11434"
CORE_LLM_MODEL="mistral"
```

- Sauvegardez le fichier.
- Lancez enfin l'agent Hermes :

```
npm start
```

Votre agent Hermes est désormais opérationnel et propulsé par votre IA locale !

7. FAQ & Dépannage

Pourquoi les réponses sont-elles très lentes ?

Si vous n'avez pas de carte graphique dédiée compatible (GPU), Ollama utilise votre processeur (CPU). C'est beaucoup plus lent. Si c'est votre cas, passez sur un modèle plus petit comme **Phi-3**.

Erreur : "Connection refused"

Vérifiez que l'application Ollama est bien lancée et active en arrière-plan (regardez dans la barre des tâches) avant de démarrer Hermes.